

Laporan Praktikum Kontrol Cerdas

Nama : Inggar Mahesa Yudanto
Nim : 224308084
Kelas : TKA – 7D
Akun Github (Tautan) : <https://github.com/Inggarmahesa>
Student Lab Assistant : -

1. Judul Percobaan

Deep Reinforcement Learning untuk Kontrol Kompleks.

2. Tujuan Percobaan

Tujuan dari praktikum “*Deep Reinforcement Learning* untuk Kontrol Kompleks”, mahasiswa diharapkan mampu:

1. Menganalisis kemampuan algoritma DQN dalam mengonversi input lingkungan (seperti kecepatan, posisi, atau sinyal sensor) menjadi keputusan aksi yang tepat secara real-time.
2. Menguji stabilitas dan efisiensi kontrol otomatis yang dihasilkan oleh model DQN dibandingkan dengan metode kontrol konvensional.
3. Mengevaluasi proses pembelajaran agen DQN, yaitu bagaimana nilai *reward* memengaruhi strategi pengambilan keputusan pada sistem yang kompleks.
4. Menilai penerapan DQN sebagai dasar pengembangan sistem kontrol cerdas pada bidang-bidang seperti transportasi otomatis, robotik, maupun sistem industri berbasis sensor.

3. Landasan Teori

Deep Reinforcement Learning (DRL) merupakan pengembangan dari *Reinforcement Learning* (RL) yang menggabungkan kemampuan pembelajaran berbasis pengalaman dengan kekuatan representasi dari jaringan saraf tiruan (*deep neural network*). Dalam sistem DRL, agen belajar untuk menentukan aksi terbaik berdasarkan kondisi lingkungan guna memaksimalkan nilai *reward* jangka panjang. Metode ini banyak

diterapkan untuk sistem kontrol otomatis yang kompleks, seperti pengaturan lalu lintas, robotika, dan kendaraan otonom. Menurut (Raras Cita Utami, 2023) dalam Implementasi Algoritma *Deep Q-Network* (DQN) pada Lampu Lalu Lintas Adaptif Berdasarkan Waktu Tunggu dan Arus Kendaraan, penggunaan DQN mampu meningkatkan efisiensi pengaturan sinyal lalu lintas dengan cara menyesuaikan durasi lampu hijau dan merah berdasarkan kondisi *real-time*. Penelitian ini menunjukkan bahwa pendekatan DQN efektif untuk mengoptimalkan kontrol sistem dinamis dengan banyak variabel yang berubah secara acak.

DQN sendiri merupakan varian dari algoritma *Q-Learning* yang menggunakan *deep neural network* untuk memperkirakan nilai fungsi aksi (*action-value function*). Pendekatan ini mengatasi keterbatasan *Q-Learning* konvensional yang hanya efektif pada ruang keadaan kecil. (Abdillah & Tjendrowasono, 2022) dalam jurnal Rekayasa Sistem Informasi dan Teknologi menjelaskan bahwa DQN mampu mempelajari pola keputusan optimal pada sistem otomatis yang memiliki banyak kemungkinan aksi dan keadaan, seperti sistem perdagangan otomatis berbasis data waktu nyata. Dengan kata lain, DQN membuat sistem kontrol mampu beradaptasi terhadap perubahan lingkungan tanpa memerlukan model matematis eksplisit dari sistem tersebut.

Lebih lanjut, (Setiawan, 2024) dalam Jurnal FAITH menunjukkan penerapan DQN pada simulasi kendaraan otonom yang dapat menyesuaikan gaya berkendara berdasarkan kondisi lalu lintas dan kecepatan. Melalui pembelajaran berulang, agen DQN dapat mengenali situasi berisiko dan melakukan aksi yang meminimalkan kesalahan atau tabrakan. Hal ini menegaskan bahwa algoritma DQN memiliki potensi besar dalam mengembangkan sistem kontrol cerdas yang adaptif, terutama pada aplikasi dunia nyata yang kompleks seperti transportasi dan robotik.

Secara umum, keunggulan utama DQN dalam kontrol otomatis terletak pada kemampuannya untuk menggabungkan *perception* (melalui *deep learning*) dan *decision-making* (melalui *reinforcement learning*). Dengan

pendekatan ini, sistem tidak hanya bereaksi terhadap kondisi saat ini tetapi juga belajar dari pengalaman masa lalu untuk mengambil keputusan yang lebih optimal di masa depan. Oleh karena itu, penerapan DQN dalam sistem kontrol otomatis menjadi langkah penting menuju otomatisasi yang lebih adaptif, efisien, dan cerdas.

4. Analisis dan Diskusi

Analisis :

hasil implementasi algoritma *Deep Q-Network* (DQN) pada *environment CartPole-v1* dan *Pendulum-v1* menunjukkan bahwa pendekatan pembelajaran penguatan (*reinforcement learning*) mampu mengoptimalkan perilaku agen dalam menghadapi dinamika sistem yang berbeda. Pada *CartPole*, agen dilatih untuk menjaga keseimbangan tiang pada kereta dengan melakukan aksi kiri atau kanan berdasarkan observasi posisi, kecepatan, sudut, dan kecepatan sudut tiang. Selama proses pelatihan, nilai *epsilon* secara bertahap menurun sesuai strategi *epsilon decay*, yang menyeimbangkan antara eksplorasi dan eksploitasi. Hasilnya, skor episode meningkat seiring waktu, menunjukkan bahwa agen berhasil belajar mempertahankan tiang lebih lama dalam posisi tegak, yang terlihat dari grafik episode vs *score* yang cenderung meningkat secara stabil.

Sementara itu, pada *Pendulum-v1*, sistem memiliki tingkat kompleksitas lebih tinggi karena aksi bersifat kontinu dan perlu didekati secara diskret menggunakan nilai aksi tetap (-2.0, 0.0, 2.0). Proses pelatihan melibatkan dua jaringan saraf model utama (*main network*) dan *target network* yang diperbarui secara periodik untuk meningkatkan stabilitas pembelajaran. *Reward* yang diperoleh dinormalisasi agar proses konvergensi lebih halus. Dari hasil pelatihan, terlihat bahwa total *reward* meningkat secara bertahap seiring berkurangnya nilai *epsilon*, menandakan agen semakin optimal dalam menjaga posisi pendulum tetap tegak dan mengurangi energi yang dibutuhkan. Grafik *reward* memperlihatkan tren kenaikan yang menunjukkan keberhasilan pembelajaran meski fluktuatif karena sifat *continuous control* pada

environment ini.

Secara keseluruhan, penerapan DQN pada kedua *environment* membuktikan kemampuan algoritma ini dalam mengatasi permasalahan kontrol dinamis berbasis penguatan. Pada *CartPole*, agen belajar dengan cepat karena aksi dan keadaan relatif sederhana, sedangkan pada Pendulum, meskipun lebih sulit, DQN tetap mampu mencapai performa yang baik melalui kombinasi pengalaman *replay*, pembaruan target *network*, dan penurunan nilai *epsilon* secara bertahap..

Diskusi :

Pada *CartPole-v1*, sistem bersifat diskret baik pada ruang aksi maupun observasinya, sehingga algoritma DQN mampu beradaptasi dengan cepat. Agen hanya perlu memilih antara dua aksi menggerakkan kereta ke kiri atau ke kanan untuk menjaga keseimbangan tiang. Selama pelatihan, nilai *epsilon* yang menurun secara bertahap membantu agen beralih dari fase eksplorasi (mencoba aksi acak) ke fase eksploitasi (mengambil aksi terbaik berdasarkan nilai Q yang telah dipelajari). Hasilnya, grafik *reward* menunjukkan peningkatan yang stabil, menandakan bahwa agen berhasil belajar strategi optimal untuk menjaga tiang tetap tegak lebih lama. Hal ini menunjukkan bahwa DQN bekerja sangat efektif pada *environment* dengan ruang aksi terbatas dan deterministik seperti *CartPole*.

Sebaliknya, pada Pendulum-v1, tantangan muncul karena ruang aksinya bersifat kontinu, di mana aksi dapat berupa nilai torsi dalam rentang tertentu. Karena DQN hanya dapat menangani aksi diskret, diperlukan pendekatan diskretisasi aksi menjadi beberapa nilai tetap (-2.0, 0.0, 2.0). Meskipun solusi ini membuat algoritma DQN tetap dapat diterapkan, hasilnya tidak seoptimal algoritma *continuous-action* lain seperti DDPG atau TD3. *Reward* yang diperoleh selama pelatihan cenderung berfluktuasi sebelum akhirnya meningkat secara perlahan. Namun, penggunaan target *network* dan *experience replay* terbukti membantu stabilitas pembelajaran dengan mencegah *overfitting* dan

memperlambat osilasi nilai Q.

Secara keseluruhan, hasil diskusi menunjukkan bahwa DQN sangat efektif untuk permasalahan kontrol sederhana dengan aksi diskret, tetapi memiliki keterbatasan pada *environment* dengan aksi kontinu seperti Pendulum. Meskipun demikian, performa agen masih dapat ditingkatkan melalui modifikasi seperti penggunaan double DQN, *dueling network*, atau mengganti metode dengan algoritma *actor-critic* yang lebih cocok untuk *continuous control*. Dengan demikian, eksperimen ini memberikan pemahaman mendalam mengenai keunggulan dan keterbatasan DQN dalam berbagai jenis permasalahan penguatan..

5. Assignment





Pada tugas ini, algoritma *Deep Q-Network* (DQN) dimodifikasi untuk diterapkan pada sistem kontrol lain yang lebih kompleks, seperti pengendalian lengan robot dan optimasi energi pada kendaraan listrik. Dalam pengendalian lengan robot, DQN berperan untuk menentukan aksi torsi optimal pada setiap sendi agar ujung lengan mencapai posisi target dengan presisi tinggi dan waktu minimum. Proses pembelajaran dilakukan melalui interaksi langsung dengan lingkungan, di mana agen memperoleh *reward* positif jika posisi mendekati target dan *penalty* bila terjadi deviasi atau getaran berlebih. Pendekatan serupa juga dapat diterapkan pada kendaraan listrik, di mana DQN digunakan untuk mengoptimalkan pola akselerasi dan pengereman agar konsumsi energi lebih efisien tanpa mengorbankan kenyamanan dan keamanan pengendalian.

Jika dibandingkan dengan metode kontrol klasik seperti PID (Proportional–Integral–Derivative) atau *Fuzzy Logic*, DQN memiliki keunggulan utama pada kemampuan adaptasi terhadap sistem *nonlinear* dan kondisi dinamis yang sulit dimodelkan secara matematis. PID memberikan respon cepat dan stabil pada sistem linear, namun kinerjanya menurun pada sistem dengan ketidakpastian tinggi. *Fuzzy Logic* lebih fleksibel, tetapi membutuhkan rancangan aturan (*rule base*) yang rumit

dan bergantung pada pengalaman perancang.

Dengan demikian, DQN lebih unggul dalam konteks sistem kompleks karena dapat belajar dari pengalaman dan menyesuaikan strategi kontrolnya secara mandiri. Namun, metode klasik tetap relevan karena memiliki keandalan tinggi dan waktu respon yang cepat. Pendekatan hibrid, yaitu menggabungkan DQN dengan PID atau *Fuzzy*, dapat menjadi solusi terbaik untuk mencapai sistem kontrol yang stabil, adaptif, dan efisien secara.

6. Data dan Output Hasil Pengamatan

No	Variabel	Hasil Pengamatan	
		CartPole-v1	Pendulum-v1
1.	Waktu pelatihan	 Terlihat bahwasanya pada saat awal episode grafik tersebut menunjukkan skor masih dalam kondisi yang rendah serta fluktuasi, dikarenakan agen masih beradaptasi dan belajar mengeksplorasi lingkungan. Dan seiring bertambahnya episode skor meningkat hingga pada nilai maksimum.	 Pada awal episode <i>reward</i> meningkat tajam, serta pada saat kondisi hampir mendekati nilai maksimum maka kondisi stabil, hal ini menandakan agen telah berhasil mempelajari strategi kontrol optimal.
2.	Kinerja agen	 pada grafik tersebut menunjukkan bahwa kinerja agen DQN masih belum stabil, dengan skor yang naik turun. Agen masih belajar mengeksplorasi tindakan	 Terlihat bahwa total <i>reward</i> awalnya sangat rendah, lalu meningkat tajam di beberapa episode sebelum kembali turun.

		dan belum menemukan strategi optimal untuk menjaga keseimbangan tiang.	Ini menandakan kinerja agen masih fluktuatif, belum sepenuhnya stabil dalam menjaga keseimbangan pendulum, meskipun sempat menunjukkan peningkatan performa di tengah pengujian.																																													
3.	Kondisi berhasil	Kalau pada <i>CartPole</i> , kondisi berhasil ditandai dengan skor tinggi dan stabil, biasanya mendekati nilai maksimum 500. Artinya, agen DQN berhasil menjaga tiang tetap tegak di atas gerobak selama seluruh durasi episode tanpa jatuh. Pada tahap ini, gerakan gerobak menjadi lebih halus dan terarah, menunjukkan agen sudah memahami strategi optimal untuk menyeimbangkan tiang secara konsisten.	Ketika pendulum berhasil, <i>reward</i> akan bernilai kecil negatif atau mendekati nol, menandakan agen mampu menjaga pendulum tetap tegak dan stabil tanpa banyak gerakan berputar. Dalam kondisi ini, torsi yang diberikan sudah seimbang dan halus, sehingga pendulum hanya berayun sedikit di sekitar posisi vertikal dan tidak lagi melakukan putaran penuh. Ini menunjukkan kontrol agen sudah optimal.																																													
4.	Hasil episode	 <table><tr><td>Episode 1/10</td><td>Score: 12.00</td><td>Epsilon: 1.000</td></tr><tr><td>Episode 2/10</td><td>Score: 17.00</td><td>Epsilon: 0.995</td></tr><tr><td>Episode 3/10</td><td>Score: 25.00</td><td>Epsilon: 0.990</td></tr><tr><td>Episode 4/10</td><td>Score: 21.00</td><td>Epsilon: 0.985</td></tr><tr><td>Episode 5/10</td><td>Score: 36.00</td><td>Epsilon: 0.980</td></tr><tr><td>Episode 6/10</td><td>Score: 21.00</td><td>Epsilon: 0.975</td></tr><tr><td>Episode 7/10</td><td>Score: 13.00</td><td>Epsilon: 0.970</td></tr><tr><td>Episode 8/10</td><td>Score: 39.00</td><td>Epsilon: 0.966</td></tr><tr><td>Episode 9/10</td><td>Score: 16.00</td><td>Epsilon: 0.961</td></tr></table> Berdasarkan hasil episode, skor terbaik mencapai 39 pada episode ke 7. Nilai ini menunjukkan bahwa pada episode tersebut, agen DQN berhasil menjaga tiang tetap seimbang	Episode 1/10	Score: 12.00	Epsilon: 1.000	Episode 2/10	Score: 17.00	Epsilon: 0.995	Episode 3/10	Score: 25.00	Epsilon: 0.990	Episode 4/10	Score: 21.00	Epsilon: 0.985	Episode 5/10	Score: 36.00	Epsilon: 0.980	Episode 6/10	Score: 21.00	Epsilon: 0.975	Episode 7/10	Score: 13.00	Epsilon: 0.970	Episode 8/10	Score: 39.00	Epsilon: 0.966	Episode 9/10	Score: 16.00	Epsilon: 0.961	 <table><tr><td>Episode 1/10</td><td>Total Reward: -1022.23</td></tr><tr><td>Episode 2/10</td><td>Total Reward: -965.60</td></tr><tr><td>Episode 3/10</td><td>Total Reward: -983.53</td></tr><tr><td>Episode 4/10</td><td>Total Reward: -1042.31</td></tr><tr><td>Episode 5/10</td><td>Total Reward: -1018.12</td></tr><tr><td>Episode 6/10</td><td>Total Reward: -398.94</td></tr><tr><td>Episode 7/10</td><td>Total Reward: -146.31</td></tr><tr><td>Episode 8/10</td><td>Total Reward: -22.20</td></tr><tr><td>Episode 9/10</td><td>Total Reward: -1019.96</td></tr></table> Berdasarkan hasil yang ditampilkan, <i>reward</i> masih didominasi oleh nilai negatif besar, seperti -1022.23 hingga -983.53 pada beberapa episode awal. Hal ini menunjukkan bahwa	Episode 1/10	Total Reward: -1022.23	Episode 2/10	Total Reward: -965.60	Episode 3/10	Total Reward: -983.53	Episode 4/10	Total Reward: -1042.31	Episode 5/10	Total Reward: -1018.12	Episode 6/10	Total Reward: -398.94	Episode 7/10	Total Reward: -146.31	Episode 8/10	Total Reward: -22.20	Episode 9/10	Total Reward: -1019.96
Episode 1/10	Score: 12.00	Epsilon: 1.000																																														
Episode 2/10	Score: 17.00	Epsilon: 0.995																																														
Episode 3/10	Score: 25.00	Epsilon: 0.990																																														
Episode 4/10	Score: 21.00	Epsilon: 0.985																																														
Episode 5/10	Score: 36.00	Epsilon: 0.980																																														
Episode 6/10	Score: 21.00	Epsilon: 0.975																																														
Episode 7/10	Score: 13.00	Epsilon: 0.970																																														
Episode 8/10	Score: 39.00	Epsilon: 0.966																																														
Episode 9/10	Score: 16.00	Epsilon: 0.961																																														
Episode 1/10	Total Reward: -1022.23																																															
Episode 2/10	Total Reward: -965.60																																															
Episode 3/10	Total Reward: -983.53																																															
Episode 4/10	Total Reward: -1042.31																																															
Episode 5/10	Total Reward: -1018.12																																															
Episode 6/10	Total Reward: -398.94																																															
Episode 7/10	Total Reward: -146.31																																															
Episode 8/10	Total Reward: -22.20																																															
Episode 9/10	Total Reward: -1019.96																																															

		lebih lama dibanding episode lainnya. Meskipun belum mencapai skor maksimum (500), hasil ini menandakan bahwa agen mulai memahami strategi kontrol yang efektif, dan performanya berpotensi meningkat jika pelatihan dilanjutkan.	pendulum masih berputar terus dan belum stabil, karena agen memberikan torsi berlebihan untuk menjaga keseimbangan. Namun, pada episode ke-8 dengan <i>reward</i> -22.20, terlihat peningkatan performa yang signifikan, menandakan pendulum mulai stabil dan mampu dipertahankan di posisi seimbang.
--	--	---	---

7. Kesimpulan

Dari hasil praktikum ini dapat ditarik kesimpulan sebagai berikut :

1. Agen DQN pada *CartPole* mampu belajar menyeimbangkan tiang dengan skor terbaik 39 pada episode ke-7, menandakan kemampuan kontrol mulai terbentuk.
2. Kinerja agen belum stabil sepenuhnya, karena skor masih fluktuatif dan belum mencapai nilai maksimum (500).
3. Pada Pendulum, *reward* awal sangat negatif (sekitar -1000) menandakan pendulum berputar terus dan belum seimbang.
4. Pada episode ke-8, *reward* meningkat menjadi sekitar -22, menunjukkan pendulum mulai stabil dan agen memahami pola kontrolnya.
5. Secara umum, DQN efektif dalam pembelajaran adaptif tanpa model matematis, namun memerlukan lebih banyak episode dan tuning parameter untuk mencapai hasil yang benar-benar optimal.

8. Saran

Saran ke depannya agar praktikum dikembangkan menggunakan sistem kontrol nyata seperti *robotic arm* atau motor DC, serta membandingkan DQN dengan algoritma lain seperti DDPG atau PPO untuk meningkatkan akurasi dan stabilitas pembelajaran.

9. Daftar Pustaka

- Abdillah, B., & Tjendrowasono. (2022). Pengaplikasian Deep Reinforcement Q-Learning untuk Prediksi Perdagangan Valas Otomatis. Jurnal Rekayasa Sistem Informasi dan Teknologi. Universitas Surakarta.
- Raras Cita Utami. (2023). Implementasi Algoritma Deep Q-Network (DQN) pada Lampu Lalu Lintas Adaptif Berdasarkan Waktu Tunggu dan Arus Kendaraan. Repositori Universitas Islam Indonesia.
- Setiawan. (2024). Exploring Deep Q-Network for Autonomous Driving Simulation. Jurnal FAITH, 7.